

Analisi dei fattori di rischio del diabete

Sofia Menegozzo

Giugno 2026

Indice

1	Introduzione	2
1.1	Contesto medico	2
1.2	Obiettivo del progetto	2
2	Dataset e preprocessing	3
2.1	Dataset e fonti	3
2.2	Preprocessing	3
3	Analisi descrittive	5
3.1	Distribuzione della variabile target	5
4	Analisi statistica	9
4.1	Fattori di rischio	9
4.2	Analisi inferenziale	10
4.3	Analisi della matrice di correlazione	11
5	Modello predittivo	13
5.1	Regressione	13
5.2	Predittori e Matrice di confusione	13
5.3	Validazione del modello e generalizzazione	17
5.4	Gestione dello sbilanciamento delle classi	17
6	Interpretazione del modello	19
6.1	Odds Ratio	19
6.2	Coefficienti di regressione	21
6.3	Calibrazione del modello	21
7	Limiti dello studio	23
8	Conclusioni	25

1 Introduzione

1.1 Contesto medico

Il diabete rappresenta una delle principali patologie croniche a livello globale secondo le linee guida dell'American Diabetes Association.

Si tratta di una malattia metabolica caratterizzata da livelli elevati di glucosio nel sangue, dovuti a una produzione insufficiente di insulina o a un utilizzo inefficace di quest'ultima da parte dell'organismo. Nel lungo periodo, il diabete può provocare complicanze anche gravi, come malattie cardiovascolari, insufficienza renale, neuropatie e problemi alla vista, che influenzano in modo significativo la qualità della vita dei pazienti.

Negli ultimi decenni, la diffusione del diabete è aumentata in modo considerevole, anche a causa dell'invecchiamento della popolazione, dell'aumento dell'obesità e della diffusione di stili di vita sedentari.

1.2 Obiettivo del progetto

L'obiettivo di questo progetto è analizzare i principali fattori associati alla presenza del diabete attraverso tecniche di analisi descrittiva, inferenziale e predittiva. In particolare, il lavoro si concentra sull'individuazione delle variabili maggiormente correlate alla malattia e sulla costruzione di un modello di regressione logistica in grado di stimare la probabilità che un individuo sia diabetico sulla base delle sue caratteristiche cliniche, comportamentali e socioeconomiche.

L'analisi si sviluppa in diverse fasi:

1. Esplorazione del dataset tramite statistiche descrittive e visualizzazioni grafiche, con l'obiettivo di comprendere la distribuzione delle variabili e le differenze tra soggetti diabetici e non diabetici.
2. Analisi delle relazioni statistiche tra le variabili mediante correlazioni, test statistici e analisi comparative.
3. Sviluppo e valutazione di un modello di regressione logistica per la classificazione dei soggetti a rischio di diabete, utilizzando metriche predittive come Accuracy, Recall, F1-score, ROC curve e AUC.

2 Dataset e preprocessing

2.1 Dataset e fonti

Il dataset utilizzato nel progetto deriva dal Behavioral Risk Factor Surveillance System (BRFSS)¹, un'indagine sanitaria condotta annualmente dai Centers for Disease Control and Prevention (CDC) negli Stati Uniti. Il BRFSS raccoglie informazioni relative allo stato di salute e ai principali fattori di rischio della popolazione adulta americana attraverso interviste telefoniche standardizzate. Il dataset è disponibile pubblicamente sulla piattaforma Kaggle² in una versione già preprocessata per finalità di data analysis e machine learning.

Il dataset finale contiene 229.781 osservazioni e 22 variabili che riguardano diversi aspetti della salute e dello stile di vita degli individui, come la pressione alta, il colesterolo elevato, il BMI (Body Mass Index)³, l'attività fisica, il consumo di frutta e verdura, il fumo, il consumo di alcol, la salute fisica e mentale, le difficoltà motorie, l'età, il livello di istruzione e il reddito.

La variabile target del modello è *diabetes*, codificata in forma binaria:

- 1 = presenza di diabete
- 0 = assenza di diabete

2.2 Preprocessing

Prima di procedere con l'analisi statistica, il dataset è stato sottoposto a una fase preliminare di pulizia e preparazione dei dati utilizzando Python. Questa fase consente di garantire la qualità del dataset e migliorare l'affidabilità dei risultati ottenuti.

In particolare, sono state eseguite operazioni di importazione del dataset tramite librerie Python dedicate alla gestione dei dati, analisi della struttura del database e dei relativi tipi di variabili, individuazione di eventuali valori mancanti e record duplicati, selezione delle variabili considerate utili ai fini dello studio, verifica della corretta codifica delle variabili categoriche e binarie ed esportazione del dataset finale pulito, successivamente utilizzato per le analisi statistiche in R.

L'analisi preliminare ha evidenziato l'assenza di valori mancanti, pertanto non sono state applicate tecniche di imputazione o rimozione delle osservazioni incomplete. Anche la struttura delle variabili risultava già coerente e pronta per l'analisi statistica.

¹Il Behavioral Risk Factor Surveillance System (BRFSS) è un sistema di sorveglianza sanitaria sviluppato dai Centers for Disease Control and Prevention (CDC) degli Stati Uniti.

²<https://www.kaggle.com/datasets/alexteboul/diabetes-health-indicators-dataset>

³L'indice di massa corporea (BMI) è classificato secondo le linee guida dell'Organizzazione Mondiale della Sanità: <https://www.who.int/data/gho/data/themes/topics/topic-details/GHO/body-mass-index>

Per la fase di preprocessing sono state utilizzate principalmente le librerie Python:

- **pandas** per la gestione dei dataframe;
- **numpy** per le operazioni numeriche;
- **matplotlib e seaborn** per alcune visualizzazioni preliminari.

Successivamente, il dataset preprocessato è stato importato in R, ambiente principale utilizzato per l'analisi statistica, la regressione logistica e la costruzione delle visualizzazioni finali.

L'integrazione tra Python e R ha permesso di combinare la flessibilità del preprocessing in Python con la potenza degli strumenti statistici disponibili in R, rendendo il workflow dell'analisi più completo ed efficiente.

3 Analisi descrittive

3.1 Distribuzione della variabile target




Figura 3.1: Distribuzione della variabile target

Il dataset mostra una popolazione composta da 229.781 individui e una variabile target (diabetes) fortemente sbilanciata, infatti circa il 17,3% dei soggetti risulta diabetico, mentre l'82,7% non presenta diabete.

Come si può osservare anche dalla *Figura 3.1* è presente uno squilibrio tra i soggetti con e senza diabete, ciò indica che il diabete rappresenta un evento relativamente meno frequente nel campione, ma comunque epidemiologicamente rilevante.

Caratteristiche generali della popolazione

BMI




Figura 3.2: Distribuzione della variabile BMI

L'indice di massa corporea (BMI), la cui classificazione è riportata nella Tabella 3.1, presenta un valore medio pari a 28,69 (DS = 6,79), indicando una popolazione mediamente in sovrappeso.

I soggetti diabetici mostrano un BMI medio superiore rispetto ai non diabetici (31,8 contro 28,0), come evidenziato nella Figura 3.2. La distribuzione del BMI nei soggetti diabetici (1) risulta infatti spostata verso valori maggiori rispetto a quella dei non diabetici (0), evidenziando una maggiore concentrazione di individui con BMI elevato. Questo andamento è visibile nel grafico dal fatto che la distribuzione dei diabetici si colloca più a destra lungo l'asse delle ascisse.

Questo risultato è coerente con la letteratura scientifica, secondo cui l'eccesso di peso rappresenta uno dei principali fattori di rischio per il diabete di tipo 2.

BMI	Categoria
$< 18,5$	Sottopeso
$18,5 - 24,9$	Normopeso (peso forma)
$25 - 29,9$	Sovrappeso
$30 - 34,9$	Obesità di primo grado
$35 - 39,9$	Obesità di secondo grado
≥ 40	Obesità di terzo grado (o grave)

Tabella 3.1: Classificazione del BMI secondo l'OMS

Età




Figura 3.3: Boxplot della variabile età

L'età media, espressa tramite la variabile categoriale *age* (Tabella 3.2), è pari a 8,09 (DS = 3,09), indicando una prevalenza di soggetti appartenenti a fasce d'età adulte.

I soggetti diabetici appartengono mediamente a classi di età più avanzate rispetto ai non diabetici (9,34 contro 7,82). La Figura 3.3 evidenzia una distribuzione complessivamente

spostata verso età più elevate nei soggetti diabetici, suggerendo un aumento della probabilità di diabete con l'invecchiamento.

Sono inoltre presenti alcuni outlier a età più basse, che potrebbero riflettere casi di diabete a insorgenza precoce.

Codice	Fascia d'età
1	18–24 anni
2	25–29 anni
3	30–34 anni
4	35–39 anni
5	40–44 anni
6	45–49 anni
7	50–54 anni
8	55–59 anni
9	60–64 anni
10	65–69 anni
11	70–74 anni
12	75–79 anni
13	80 anni o più

Tabella 3.2: Classificazione della variabile *age* in classi di età

Stato di salute percepito




Figura 3.4: Boxplot della variabile *general_health* (salute generale)

Per quanto riguarda lo **stato di salute percepito**, i giorni medi di cattiva salute generale negli ultimi 30 giorni risultano pari a 2,68, quelli di salute fisica 4,68, mentre quelli relativi alla salute mentale sono pari a 3,51. La variabile *general_health* evidenzia una percezione dello stato di salute peggiore nei soggetti diabetici. La media passa infatti da 2,46 nei

non diabetici a 3,26 nei diabetici (dove valori più alti indicano salute peggiore). Analogamente, i diabetici riportano molti più giorni di cattiva salute fisica (7,82 contro 4,02) e mentale (4,50 contro 3,30). Come si può notare anche nella *Figura 3.4* dai boxplot, la popolazione diabetica ha una salute peggiore rispetto a quella non diabetica. Questo suggerisce che il diabete non sia solo una condizione metabolica isolata, ma una patologia associata a un generale peggioramento della qualità della vita. Si osserva una migliore salute generale nei soggetti non diabetici, tanto che il terzo quartile di questa popolazione è all'incirca equivalente al primo quartile della popolazione affetta da diabete.

4 Analisi statistica

4.1 Fattori di rischio

Dalle statistiche descrittive emerge una prevalenza elevata di alcuni fattori di **rischio cardiovascolare**, il 45,4% degli individui presenta **ipertensione** (high_bp) e il 44,2% livelli elevati di **colesterolo** (high_chol).

La maggior parte del campione dichiara di svolgere **attività fisica** (physical_activity 73,3%) e di avere **accesso all'assistenza sanitaria** (healthcare 94,6%). Tuttavia, circa il 18,5% riferisce **difficoltà nella deambulazione** (diff_walk) e il 10,3% una storia di **malattie cardiache** (heart_disease).

In particolare, tra gli individui con **ipertensione** la prevalenza di diabete raggiunge il 28,1%, contro l'8,3% osservato nei soggetti senza pressione alta. Un andamento analogo emerge per il **colesterolo elevato**, il diabete interessa il 26,0% dei soggetti con high_chol, rispetto al 10,4% di coloro che non presentano tale condizione.

Anche il **fumo** mostra una relazione positiva con la malattia, sebbene meno marcata, infatti i fumatori presentano una prevalenza di diabete pari al 19,2%, contro il 15,7% dei non fumatori.

L'**attività fisica** sembra esercitare un effetto protettivo, tra gli individui fisicamente attivi la percentuale di diabetici è pari al 15,0%, mentre sale al 23,7% tra coloro che non svolgono attività fisica.

I risultati evidenziano come i principali fattori cardiovascolari e comportamentali siano associati a una maggiore presenza di diabete nel campione analizzato, mentre uno stile di vita attivo appare correlato a una minore prevalenza della patologia.




Figura 4.1: Percentuale di soggetti diabetici per fattore di rischio




Figura 4.2: Percentuale di soggetti NON diabetici per fattore di rischio

Le Figure 4.1 e 4.2 raffigurano differenze nette tra gruppi, nella Figura 4.1 sono presenti i soggetti diabetici e la presenza/l'assenza del fattore di rischio in percentuale, si osserva che le colonne rosse (presenza del fattore di rischio) sono notevolmente più alte di quelle blu (assenza del fattore di rischio), nella Figura 4.2 si osserva l'opposto, le colonne blu sono più alte rispetto a quelle rosse, pertanto in percentuale l'assenza del fattore di rischio è maggiore rispetto alla presenza.

4.2 Analisi inferenziale

L'analisi inferenziale tramite test statistici conferma che le differenze rilevate non sono dovute al caso.

I t-test per BMI ed età mostrano p-value inferiori a 2.2×10^{-16} , indicando differenze altamente significative tra diabetici e non diabetici. In particolare, i diabetici presentano un BMI medio pari a 31,82 contro 28,03 nei non diabetici, con una differenza media di circa 3,8 punti (IC 95%: -3,87 ; -3,71).

Anche per l'età emerge una differenza significativa, infatti i soggetti diabetici appartengono mediamente a classi di età superiori (media 9,34 contro 7,82 nei non diabetici), con una differenza di circa 1,5 classi di età (IC 95%: -1,54 ; -1,49).

Anche i test chi-quadro relativi a pressione alta e colesterolo alto indicano un'associazione statisticamente significativa con il diabete. Per la pressione alta il valore del chi-quadro è pari a 15573, mentre per il colesterolo alto è pari a 9600,7, entrambi con p-value $< 2.2 \times 10^{-16}$.

Questi risultati indicano che la presenza di diabete non è indipendente dalla presenza di ipertensione o colesterolo elevato.

Pertanto, la prevalenza del diabete differisce significativamente in funzione della presenza di ipertensione e colesterolo elevato.

4.3 Analisi della matrice di correlazione

L'analisi della matrice di correlazione consente di comprendere la forza e la direzione delle relazioni lineari tra le variabili del dataset e, in particolare, il loro legame con la presenza di diabete.

Analizzando le correlazioni con la variabile `diabetes`, emerge che la relazione più forte riguarda la percezione della salute generale (`general_health`, $r = 0,282$). Poiché valori più alti di questa variabile indicano condizioni di salute peggiori, il risultato suggerisce che i soggetti diabetici tendono ad avere una qualità della salute percepita significativamente peggiore rispetto ai non diabetici. Subito dopo compaiono `high_bp` (pressione alta, $r = 0,260$) e `bmi` ($r = 0,211$), confermando che ipertensione e obesità sono tra i fattori maggiormente associati alla malattia.

Anche `diff_walk` (difficoltà nel camminare, $r = 0,208$) e `high_chol` (colesterolo alto, $r = 0,204$) mostrano relazioni positive moderate ma rilevanti, suggerendo che limitazioni fisiche e alterazioni metaboliche siano strettamente collegate alla presenza del diabete.

L'età (`age`) presenta una correlazione positiva pari a 0,185, indicando che all'aumentare dell'età cresce anche la probabilità di essere diabetici.

Analogamente, `heart_disease` (malattie cardiache) e `physical_health` presentano correlazioni positive, rafforzando l'idea che il diabete sia fortemente connesso a condizioni cardiovascolari e peggioramento dello stato fisico generale.

Al contrario, alcune variabili hanno correlazioni negative con il diabete, questi sono considerate fattori protettivi. La più evidente è `income` ($r = -0,148$), perciò all'aumentare del reddito la probabilità di diabete tende a diminuire. Questo risultato può riflettere differenze nello stile di vita, nell'accesso alle cure e nella prevenzione sanitaria tra classi socioeconomiche differenti.

Anche `education` presenta una correlazione negativa ($r = -0,109$), suggerendo che livelli di istruzione più elevati siano associati a una minore prevalenza della malattia.

Tra i fattori protettivi compare anche `physical_activity` ($r = -0,102$), questo suggerisce che una maggiore attività fisica è associata a una minore probabilità di diabete.

È interessante notare che variabili come `fruits` e `veggies` presentano correlazioni molto deboli e negative, indicando che il semplice consumo dichiarato di frutta e verdura non sembra spiegare una quota importante della variabilità del diabete nel dataset.

Anche il sesso (`sex`) mostra una correlazione quasi nulla, suggerendo che il genere abbia un impatto limitato rispetto agli altri fattori.

Si osservano inoltre alcune relazioni tra i predittori, `general_health` risulta correlata con `physical_health` e con `diff_walk`. Ciò indica che le persone che percepiscono una salute peggiore tendono anche ad avere più problemi fisici e difficoltà motorie.

Allo stesso modo, education e income hanno una correlazione positiva, suggerendo che istruzione e reddito siano strettamente collegati sul piano socioeconomico.

Tuttavia, nessuna correlazione tra predittori appare sufficientemente elevata da suggerire problemi di multicollinearità. Questo viene confermato anche dall'analisi VIF (Variance Inflation Factor), tutti i valori risultano inferiori a 2, pertanto il modello non soffre di forte ridondanza tra variabili esplicative.




Figura 4.3: Matrice di correlazione contenente solo le variabili più rilevanti

5 Modello predittivo

5.1 Regressione

La regressione consente di stimare l'effetto di ciascuna variabile sul rischio di diabete controllando simultaneamente per tutte le altre variabili del modello. I coefficienti positivi indicano un aumento del rischio, mentre quelli negativi suggeriscono un effetto protettivo.

Variabile	β	p -value
high_bp	0.706	< 0.001
high_chol	0.596	< 0.001
BMI	0.060	< 0.001
stroke	0.106	< 0.001
heart_disease	0.193	< 0.001
general_health	0.486	< 0.001
sex	0.238	< 0.001
age	0.126	< 0.001
income	-0.046	< 0.001
heavy_alcohol	-0.720	< 0.001
mental_health	-0.002	0.005
physical_health	-0.006	< 0.001

Tabella 5.1: Coefficienti significativi della regressione logistica

I risultati mostrano che ipertensione, colesterolo alto e una peggiore salute generale percepita rappresentano i fattori maggiormente associati a un aumento del rischio di diabete. Anche età, BMI e presenza di patologie cardiovascolari contribuiscono positivamente al rischio.

Al contrario, un reddito più elevato risulta associato a una riduzione del rischio. La variabile heavy_alcohol mostra anch'essa un coefficiente negativo, sebbene tale risultato debba essere interpretato con cautela per possibili effetti di confondimento o caratteristiche specifiche del campione.

Le variabili physical_activity, fruits e veggies non risultano statisticamente significative al livello del 5%, suggerendo un effetto debole o non rilevabile nel modello considerato.

5.2 Predittori e Matrice di confusione

Dal punto di vista della bontà del modello, il valore di **pseudo- R^2 di McFadden** è pari a 0,185, il che indica una capacità esplicativa discreta. Nei modelli, valori tra 0,2 e 0,4 sono generalmente considerati indicativi di una discreta capacità esplicativa, dunque il

modello mostra una performance soddisfacente ma non eccellente. Ciò suggerisce che il diabete dipenda anche da altri fattori non presenti nel dataset, come genetica, alimentazione dettagliata o abitudini cliniche.

Per quanto riguarda l'**adeguatezza** del modello, la riduzione della devianza (da 211598 a 172414) indica un miglioramento sostanziale della capacità esplicativa rispetto al modello nullo, mentre l'AIC pari a 172452 conferma la bontà relativa del modello stimato.

L'**accuratezza** complessiva del modello è pari all'83,3%, valore apparentemente elevato. Tuttavia, dato lo sbilanciamento della classe target (circa l'82,7% dei soggetti non è diabetico), questa metrica da sola non è sufficiente a valutare la qualità del classificatore. Per questo motivo è più appropriato considerare anche metriche come ROC curve, Precision-Recall curve, recall, precision e F1-score.




Figura 5.1: ROC curve

La **curva ROC** rappresenta graficamente la relazione tra il True Positive Rate (sensibilità o recall) e il False Positive Rate al variare della soglia di classificazione, mostra quindi come cambia la capacità del modello di identificare correttamente i soggetti diabetici rispetto alla quantità di falsi positivi prodotti.

Nella *Figura 5.1* la ROC curve del modello si colloca nettamente sopra alla diagonale ciò indica che il classificatore possiede una reale capacità di separare i soggetti diabetici da quelli non diabetici.

L'analisi di questo grafico evidenzia una buona capacità discriminante del modello, confermata da un valore di AUC pari a 0,8. In termini pratici, ciò significa che il modello è in

grado di distinguere correttamente un soggetto diabetico da uno non diabetico nell'80% dei casi.




Figura 5.2: Precision-Recall curve

La **Precision-Recall curve** nella *Figura 5.2* risulta particolarmente rilevante in presenza di dataset sbilanciati. Il recall (o sensibilità) misura la capacità del modello di identificare correttamente i soggetti diabetici sul totale dei diabetici reali, mentre la precision indica la percentuale di soggetti classificati come diabetici che risultano effettivamente tali.

Nel grafico ottenuto la curva riflette il compromesso tra precision e recall al variare della soglia di classificazione. In particolare, quando il modello cerca di aumentare il numero di casi positivi identificati (alto recall), tende anche ad aumentare il numero di falsi positivi, riducendo la precision. Viceversa, soglie più restrittive migliorano la precision ma riducono la capacità di individuare tutti i soggetti diabetici.

Valutazione con soglia standard (0,5)

La matrice di confusione mostra che:

- 184.382 soggetti non diabetici sono stati classificati correttamente (true negatives).
- 7.104 diabetici sono stati identificati correttamente (true positives).
- 5.673 non diabetici sono stati classificati erroneamente come diabetici (false positives).
- 32.622 diabetici non sono stati riconosciuti dal modello (false negatives).

Il dato più critico riguarda i falsi negativi, il modello riesce a individuare solo il 17,9% dei

diabetici reali ($\text{Sensitivity} = 0,179$), tuttavia oltre l'80% dei soggetti diabetici viene perso. In ambito clinico questo rappresenta un limite rilevante, poiché il costo di una mancata diagnosi è generalmente molto più alto rispetto a un falso allarme.

D'altra parte, la specificità è molto elevata (0,970), indicando che il modello identifica correttamente il 97% dei soggetti sani.

Questo comportamento suggerisce che il classificatore è estremamente conservativo e tende a prevedere la classe positiva solo quando la probabilità stimata è molto elevata. La precision (0,556) è discreta, circa il 56% dei soggetti classificati come diabetici lo è realmente; tuttavia, il F1-score pari a 0,271 evidenzia uno scarso equilibrio tra precision e recall, confermando una limitata capacità complessiva nel riconoscimento della classe positiva.

Modifica della soglia di classificazione (0,3)




Figura 5.3: Matrice di confusione (threshold = 0.3)

Per migliorare la capacità del modello di identificare i soggetti diabetici, la soglia di classificazione è stata ridotta da 0,5 a 0,3.

Con threshold pari a 0,3, il comportamento del modello cambia, l'accuratezza scende dall'83,3% all'80,4% e il recall aumenta dal 17,9% al 48,9%.

Come si può vedere dalla *Figura 5.3* che rappresenta la matrice di confusione i veri positivi passano da 7.104 a 19.430 e i falsi negativi si riducono drasticamente da 32.622 a circa 20.296.

Il modello diventa più sensibile e riesce a identificare quasi la metà dei soggetti diabetici,

tuttavia la precision diminuisce da 0,556 a 0,439, indicando un aumento dei falsi positivi. Nei contesti di screening sanitario questo compromesso è generalmente accettabile, poiché è preferibile sottoporre soggetti sani ad ulteriori accertamenti piuttosto che non identificare pazienti realmente malati.

Anche **F1-score** migliora e passa da 0,271 a 0,463, indicando un miglior equilibrio tra precision e recall. Inoltre, la balanced accuracy aumenta da 0,574 a 0,679, confermando un miglior bilanciamento tra sensibilità e specificità.

L'AUC pari a 0,80 conferma una buona capacità discriminante complessiva del modello. Anche la Precision-Recall curve supporta questa interpretazione, evidenziando che il modello ha una capacità ragionevole di identificare la classe positiva nonostante lo sbilanciamento.

5.3 Validazione del modello e generalizzazione

Un aspetto fondamentale dell'analisi predittiva riguarda la validazione del modello e la sua capacità di generalizzare su dati non utilizzati nella fase di stima.

Nello studio è stato introdotto un approccio di validazione più rigoroso basato su suddivisione del dataset in training set e test set (70% - 30%).

I risultati ottenuti sul test set confermano una buona capacità discriminante del modello, con un valore di AUC pari a circa 0,80 e un'accuracy di circa 0,80 utilizzando una soglia di classificazione pari a 0,3. La sensibilità e la specificità risultano rispettivamente pari a circa 0,49 e 0,87, indicando un compromesso tra identificazione dei soggetti positivi e contenimento dei falsi positivi.

Inoltre per valutare la stabilità del modello è stata implementata una cross-validation a 10 fold, questa ha confermato la robustezza del modello anche su diverse partizioni del dataset.

Nel complesso, queste analisi indicano che il modello mantiene prestazioni coerenti anche in validazione out-of-sample, riducendo il rischio di overfitting e fornendo una stima più affidabile della sua capacità predittiva.

5.4 Gestione dello sbilanciamento delle classi

Per affrontare il problema dello sbilanciamento della variabile target, sono state sperimentate diverse tecniche di bilanciamento del dataset, tra cui oversampling della classe minoritaria, undersampling della classe maggioritaria, utilizzo di SMOTE e assegnazione di pesi di classe nel modello logistico.

L'oversampling e l'undersampling hanno permesso di riequilibrare la distribuzione delle classi, mentre SMOTE ha generato osservazioni sintetiche della classe minoritaria migliorando la rappresentazione dello spazio delle variabili. Anche l'utilizzo di pesi di classe ha consentito di penalizzare maggiormente gli errori sulla classe minoritaria durante la stima

del modello.

Il confronto tra i diversi approcci non ha evidenziato variazioni drastiche nelle prestazioni globali in termini di AUC, che rimane stabilmente intorno a 0,80–0,81.

Tuttavia, si osservano miglioramenti marginali in alcune configurazioni bilanciate, in particolare con SMOTE, che mostra una lieve crescita della capacità discriminante.

Questi risultati suggeriscono che, sebbene lo sbilanciamento influenzi fortemente metriche, la capacità discriminante complessiva del modello rimane relativamente stabile.

6 Interpretazione del modello

6.1 Odds Ratio

Le Odds Ratio (OR), ottenute tramite l'esponenziale dei coefficienti della regressione, consentono di interpretare l'effetto delle variabili sul rischio di diabete. Un valore di OR maggiore di 1 indica un aumento delle odds di diabete, mentre un valore inferiore a 1 suggerisce un effetto protettivo.

Variabile	OR	IC 95%
high_bp	2.03	[1.97 ; 2.08]
high_chol	1.82	[1.77 ; 1.86]
general_health	1.63	[1.60 ; 1.65]
heart_disease	1.21	[1.17 ; 1.25]
diff_walk	1.13	[1.09 ; 1.16]
age	1.13	[1.13 ; 1.14]
BMI	1.06	[1.06 ; 1.06]
income	0.95	[0.95 ; 0.96]
education	0.97	[0.96 ; 0.99]
physical_activity	0.98	[0.95 ; 1.01]
fruits	0.98	[0.95 ; 1.00]
veggies	0.98	[0.95 ; 1.01]
mental_health	0.998	[0.996 ; 0.999]
physical_health	0.994	[0.992 ; 0.995]

Tabella 6.1: Odds Ratio del modello logistico

I risultati evidenziano come i principali fattori associati al diabete siano ipertensione, colesterolo alto, peggior stato di salute generale, età e BMI. In particolare, i soggetti con pressione alta presentano odds di diabete circa doppie rispetto ai soggetti senza ipertensione.

Anche le variabili cardiovascolari e funzionali, come heart_disease e diff_walk, mostrano associazioni positive significative. Al contrario, reddito e istruzione più elevati risultano associati a una riduzione moderata del rischio.

Le variabili legate allo stile di vita, come physical_activity, fruits e veggies, mostrano invece effetti deboli e non statisticamente significativi nel modello multivariato, suggerendo che parte della loro associazione sia mediata da fattori clinici più rilevanti.




Figura 6.1: Forest Plot delle Odds Ratio

Il forest plot delle Odds Ratio nella *Figura 6.2* rappresenta uno strumento efficace per quanto riguarda l'interpretazione ed evidenzia in modo chiaro il forte impatto di variabili come pressione alta, colesterolo alto e stato di salute generale sul rischio di diabete, confermando la coerenza con l'interpretazione dei coefficienti.

Interpretazione della variabile heavy_alcohol

La variabile heavy_alcohol mostra un'Odds Ratio inferiore a 1, suggerendo apparentemente una minore prevalenza di diabete nei soggetti classificati come forti consumatori di alcol. Tuttavia, tale risultato deve essere interpretato con cautela e non implica un effetto protettivo dell'alcol.

L'associazione osservata potrebbe infatti essere influenzata da diversi bias epidemiologici, tra cui reverse causality, survivor bias, collider bias e possibili fenomeni di under-reporting nei questionari auto-riferiti.

L'analisi descrittiva supporta questa interpretazione: i soggetti appartenenti al gruppo heavy_alcohol presentano mediamente età inferiore, BMI più basso e minore prevalenza di diabete rispetto agli altri gruppi, suggerendo la presenza di confondimento residuo.

Pertanto, il risultato deve essere interpretato come una possibile distorsione statistica piuttosto che come evidenza di un effetto benefico del consumo elevato di alcol.

6.2 Coefficienti di regressione

L'analisi dell'importanza delle variabili attraverso i coefficienti della regressione conferma i risultati precedenti e permette di identificare i principali determinanti del rischio di diabete.

Le variabili con impatto maggiore in termini assoluti risultano essere `high_bp` (ipertensione), `high_chol` (colesterolo alto), `general_health` (stato di salute generale), `heavy_alcohol` (consumo elevato di alcol), `sex` e `heart_disease`. Anche altre variabili come `age`, `diff_walk` e `stroke` contribuiscono al modello, ma con effetti più contenuti.

Il grafico dei coefficienti in *Figura 6.1* consente di visualizzare la direzione e l'intensità dell'effetto, i coefficienti positivi indicano un aumento del rischio di diabete mentre i coefficienti negativi indicano una riduzione delle odds della malattia.

In questo caso, fattori come ipertensione, colesterolo alto e peggior stato di salute generale sono associati a un aumento significativo del rischio, mentre alcune variabili (ad esempio `income`, `smoker`, `education` e abitudini alimentari) indicano effetti più deboli o protettivi, seppur di entità limitata.




Figura 6.2: Importanza variabili (coeff. logistica)

6.3 Calibrazione del modello

È stata analizzata la calibrazione del modello ovvero la capacità delle probabilità predette di riflettere in modo realistico le probabilità osservate, inoltre questa analisi permette una

valutazione più informativa rispetto al solo p-value.

Nella *Figura 6.3* la diagonale rappresenta la calibrazione perfetta tra probabilità predette e osservate, i punti seguono in modo abbastanza vicino questa linea, suggerendo una calibrazione complessivamente discreta del modello. Per cui le probabilità stimate risultano sufficientemente affidabili e interpretabili in termini probabilistici.




Figura 6.3: Calibration Plot

7 Limiti dello studio

Nonostante i risultati ottenuti siano coerenti con la letteratura epidemiologica sul diabete di tipo 2 e il modello mostri una buona capacità discriminante, lo studio presenta alcuni limiti importanti da considerare.

Un primo limite riguarda la natura osservazionale del dataset, le analisi consentono di individuare associazioni statistiche tra variabili e diabete, ma non permettono di stabilire relazioni causali. Variabili come pressione alta, colesterolo elevato o peggiori condizioni di salute generale possono essere associate al diabete senza rappresentarne necessariamente una causa diretta, poiché potrebbero intervenire fattori non osservati, come predisposizione genetica, alimentazione o terapie farmacologiche.

Un ulteriore limite è legato alla presenza di dati auto-riferiti (“self-reported data”), che possono introdurre bias di misurazione o errori di risposta. Variabili come attività fisica, consumo di alcol o stato di salute percepito sono soggette a interpretazioni soggettive e possibili sottostime.

Inoltre, alcune variabili sono codificate in forma categoriale o ordinale e non rappresentano valori continui reali. Ad esempio, la variabile “age” identifica classi di età e non l’età esatta; di conseguenza, il coefficiente della regressione logistica va interpretato come il passaggio a una fascia d’età superiore e non come un incremento lineare di un anno. Lo stesso vale per variabili come “general_health”, “education” e “income”, trattate come quasi continue per semplicità interpretativa e per l’elevata numerosità campionaria.

Un altro aspetto rilevante riguarda lo sbilanciamento delle classi, circa l’83% degli individui non è diabetico, mentre il 17% presenta diabete. Questo porta il modello, con soglia standard pari a 0,5, a ottenere un’accuracy elevata ma una sensibilità ridotta, favorendo la classe maggioritaria. Per migliorare il bilanciamento tra recall e precisione, la soglia è stata ridotta a 0,3.

Dal punto di vista metodologico, la regressione logistica assume relazioni lineari e additive tra variabili esplicative e log-odds del diabete. Tuttavia, nella realtà clinica alcune relazioni potrebbero essere non lineari o includere interazioni tra variabili, ad esempio tra BMI ed età o tra obesità e attività fisica. L’assenza di termini di interazione o modelli più flessibili rappresenta quindi una limitazione.

La grande numerosità campionaria (oltre 229.000 osservazioni) comporta inoltre che an-

che effetti molto piccoli risultino statisticamente significativi, con p-value estremamente bassi. Per questo motivo, l'interpretazione dei risultati è stata basata principalmente su Odds Ratio, intervalli di confidenza ed entità dell'effetto ("effect size"), piuttosto che sulla sola significatività statistica.

Infine, il modello mostra buone capacità descrittive e una discreta capacità predittiva ($AUC = 0,80$), ma non può essere considerato uno strumento diagnostico clinico. Le predizioni ottenute rappresentano probabilità statistiche e non sostituiscono valutazioni mediche o test diagnostici specifici. Inoltre, alcune valutazioni iniziali delle performance sono state effettuate sullo stesso dataset utilizzato per stimare il modello; sebbene siano state successivamente introdotte tecniche di validazione e cross-validation, questo evidenzia l'importanza di distinguere tra performance in-sample e out-of-sample.

8 Conclusioni

Nel complesso, il progetto ha permesso di analizzare i principali fattori associati al diabete attraverso tecniche di analisi descrittiva, inferenziale e predittiva. I risultati evidenziano una forte relazione tra diabete e variabili metaboliche e cardiovascolari, in particolare pressione alta, colesterolo elevato, BMI, età avanzata e peggiori condizioni di salute generale. Al contrario, livelli più elevati di istruzione e reddito risultano associati a una minore probabilità di diabete.

La regressione ha confermato l'importanza dei diversi fattori di rischio, mentre le metriche predittive hanno mostrato una buona capacità discriminante del modello, pur evidenziando le difficoltà tipiche dei dataset sbilanciati in ambito medico. La riduzione della soglia decisionale ha inoltre mostrato come, nei contesti sanitari, sia spesso preferibile privilegiare la capacità di individuare i soggetti a rischio rispetto alla sola accuracy complessiva. Dal punto di vista applicativo, lo studio conferma l'importanza della prevenzione attraverso il controllo del peso corporeo, dell'ipertensione, del colesterolo e la promozione di stili di vita salutari. I risultati confermano inoltre come il diabete sia una patologia multifattoriale influenzata da componenti metaboliche, cardiovascolari, comportamentali e socioeconomiche.

L'analisi evidenzia anche il valore dei modelli statistici e predittivi nella prevenzione sanitaria, consentendo di individuare soggetti maggiormente esposti al rischio e supportare strategie di screening precoce. Tuttavia, il modello non deve essere interpretato come uno strumento diagnostico clinico, ma come un supporto statistico all'identificazione dei fattori di rischio.

La presenza di variabili auto-riferite, lo sbilanciamento del dataset e l'assenza di informazioni genetiche o cliniche dettagliate limitano la capacità del modello di rappresentare completamente la complessità della malattia.

Futuri sviluppi potrebbero includere l'utilizzo di modelli di machine learning più avanzati, come Random Forest, Gradient Boosting o XGBoost, oltre all'integrazione di dati clinici, genetici e longitudinali per migliorare la capacità predittiva e comprendere meglio l'evoluzione del diabete nel tempo.

Nel complesso, il lavoro dimostra come l'integrazione tra analisi statistica, epidemiologia e data science possa rappresentare uno strumento efficace per comprendere fenomeni sanitari complessi e supportare attività di prevenzione e sanità pubblica.